

O melhor plano de **US\$20-40** pro chatbot do Cartório

Foco total: **atendimento WhatsApp** com voz, foto, PDF e vídeo — flows agênticos, melhor PT-BR, menor custo. Desta vez seus benchmarks do Artificial Analysis foram a fonte primária: 8 agents validaram os gaps: **multimodal, latência de chat, tool-use em flow e pipeline de mídia da Evolution API**.

11 provedores

áudio · foto · PDF · vídeo

PT-BR #1 · barato · agêntico

VEREDITO EM 10 SEGUNDOS

Gemini API PAYG · 3.6 Flash

~\$15/mês

Único modelo que entende **voice note**, **foto de documento**, **PDF** e **vídeo NATIVAMENTE** numa só chamada — sem Whisper, sem cola. PT-BR #1 (94), o mais rápido do índice (275 t/s), function calling + structured output pros flows, e o paid tier **não treina com seus dados** (DPA → LGPD ✓). Não é assinatura: é melhor — você paga só o que usa, e usa pouco.

+ Groq Whisper (STT auditável)
aceita OGG/Opus direto — o formato exato do WhatsApp

~\$1/mês

ANTES DE ASSINAR QUALQUER COISA

- ⚠ Assinatura de chat ≠ backend de bot
- ✗ ChatGPT Plus / Claude Pro (\$20) — OAuth interativo, ToS proibe alimentar serviço de terceiros, sem API inclusa.
- ✗ SuperGrok (\$30) — billing separado da API xAI. Zero créditos.
- ✗ Google AI Pro (\$20) — não libera Gemini API. O caminho é **AI Studio → API key PAYG**.
- ✗ MiniMax Token Plan (\$20) — os próprios docs dizem: "produção → PAYG". E **não existe áudio-input** na plataforma.

O NÚMERO QUE DESTRAVA A DECISÃO

Mídia custa ~\$1/mês. O cérebro é o custo.

Em 5.000 conversas/mês com 30% contendo mídia: STT Groq (10h de áudio) = **\$0.40**, visão p/ 450 fotos de RG/CPF = **\$0.45**, PDFs = **\$0.15**. Ou seja: **não escolha o provider pela mídia** — escolha pelo cérebro (PT-BR + tool-use + anti-alucinação) e plugue a mídia mais barata. Todo o pipeline de mídia cabe no troco do cafezinho.

RANKING · PERFIL DE CHATBOT (NÃO IQ BRUTO)

Os 5 finalistas

1

Gemini 3.6 Flash
Google · PAYG AI Studio

~\$15/mês real

Português 94 #1

Multimodal nativo

Velocidade 275 t/s

Tool-use (τ³) 25%

áudio+foto+PDF+vídeo nativo PT-BR #1

TTS pt nativo \$0.03/min não treina (paid)

Por que venceu: é o único "cérebro multimodal único" — a mesma chamada ouve a voice note, lê a foto do RG e responde em PT-BR impecável a 275 t/s. Custo real de 5k conversas: **~\$11** (com TTS seletivo: ~\$33). Structured output casa com os flows n8n (agendamento, protocolo, emolumento).

2

xAI API · grok-4.3
pay-as-you-go · ZDR

~\$27/mês real

Português 93

Multimodal visão+STT

Tool-use (τ³) 33%

Velocidade 69 t/s

melhor em fluxo c/ tools (τ³-Banking) ZDR self-serve

STT \$0.10/h PDF fraco sob ZDR

Plano B fortíssimo: melhor modelo em customer-service multi-turn (τ³ 33%), PT-BR 93, STT próprio a \$0.10/h e Zero Data Retention verificável por header (auditoria LGPD ♥️). grok-4.5 sobe p/ Intel 54 (~\$35). Perde pro Gemini em multimodal integrado e velocidade.

3

MiniMax Token Plan Plus
\$20 flat · OAuth nativo

\$20 flat/mês

Português ~87

Multimodal sem áudio-in

Tool-use (τ³) 13%

Anti-alucinação 84 #2

OAuth OpenClaw+Hermes TTS PT 73 vozes na quota

sem STT — voice note exige Groq/Whisper

τ³ 13%: perde o fio em fluxo

Caiu do pódio p/ chatbot: segue script perfeitamente (IFBench #1, 83) e quase não alucina (84) — ótimo p/ menus rígidos e respostas factuais. Mas WhatsApp é áudio + fluxo: sem áudio-input e com τ³ 13%, não carrega o atendimento sozinho. Papel ideal: **flat backup + TTS PT** dentro da quota dos \$20.

4

Qwen · DashScope stack
qwen3.7-plus + ASR + VL

~\$20/mês real

Português ~85?

Multimodal 85%

Tool-use (τ³) 31%

Custo mídia \$3.75

ASR PT oficial \$0.126/h VL-Flash \$0.05/1M

PT-BR texto não benchmarkado latência Singapura

O "mais completo barato": texto + ASR em PT + OCR de docs + omni numa só API OpenAI-compatible (~\$20/mês tudo). Mas o PT-BR do modelo de texto não é benchmarkado e o datacenter fica em Singapura (+200ms). Vale um piloto grátis (1M tokens/90 dias) como **terceiro rail** do LiteLLM.

5

Claude Haiku 4.5
Anthropic · PAYG + cache

~\$31/mês real

Português 92

Multimodal 60%

Documentos PDF 600 pág

Anti-alucinação 74

PDF 600 páginas inline — o melhor p/ escrituras

retenção zero default sem áudio: precisa STT externo

Especialista, não generalista: melhor PT-BR premium (92-94 na família), PDF nativo de 600 páginas e privacidade default impecável. Mas sem ouvir áudio e com tool-use modesto, entra como **escalonamento de documentos longos** (escrituras, processos) — não como voz principal do bot.

DEEP DIVE · O VENCEDOR

Gemini 3.6 Flash — o cérebro multimodal

RECOMENDADO

94 PT-BR #1 MULTILINGUAL INDEX

275 t/s MAIS RÁPIDO DO ÍNDICE

\$0.30/\$2.50 POR 1M TOKENS (IN/OUT)

1M tokens CONTEXTO

🗣 Voice note → entende direto
transcreve + raciocina + detecta emoção/idioma \$0.30/1M tok

📄 Foto de RG/CPF/comprovante
visão nativa, boa em foto torta/baixa luz ~\$0.001/foto

📄 PDF nativo até 1.000 páginas
escritura inteira sem extrair texto antes tokens/pág

📺 Vídeo nativo
tutorial/gravação enviada pelo cliente \$0.30/1M tok

🗣 TTS pt nativo (30 vozes)
responder áudio p/ quem mandou áudio \$0.03/min

✓ **LGPD ✓**: paid tier não treina modelos + Google age como data processor (DPA). Free tier treina — nunca usar em prod.

✓ **Flows ✓**: function calling + structured output (JSON schema) → agendamento, protocolo, emolumento com resposta validada.

✓ **Evolution API ✓**: mídia via base64 inline (até 20MB) ou Files API — mesmo fluxo que já baixamos no n8n.

✓ **ToS ✓**: uso comercial em chatbot explicitamente permitido; BR é região suportada.

✓ **Escalonamento**: casos jurídicos complexos → Gemini 3.1 Pro (PT-BR 94 também) por +\$3/mês.

COMPARATIVO DIRETO

PROVIDER	\$/MÊS	PT-BR	ÁUDIO	DOC/PDF	T³ FLOW	ALUC.
Gemini 3.6 Flash	~\$15	94	🟢 nativo	🟢 1000p	25%	mé
xAI grok-4.3	~\$27	93	🟢 \$0.10/h	🟡 via files	33%	mé
Qwen stack	~\$20	~85?	🟢 \$0.126/h	🟡 pág→img	31%	mé
Claude Haiku 4.5	~\$31	92	🔴 não tem	🟢 600p	~9%	baí (74)
MiniMax Plus	\$20	~87	🔴 não tem	🟡 visão	13%	baí (84)
OpenAI 5.4-nano+STT	~\$21	91	🟢 \$0.003/min	🟢 nativo	médio	🔴 a (10)
DeepSeek V4-Flash	~\$7	90	🔴 não tem	🔴 não tem	26%	🔴 a (4-6)

*Alucina" = AA-Omniscience non-hallucination (maior = melhor). Numa bot de cartório, fatos (taxas/prazos) vêm SEMPRE de tools/DB — o LLM só redige. Mesmo assim, evite os que inventam (GPT 10, DeepSeek 4-6) em document Q&A. Custo: 5k conversas/mês, 30% c/ mídia.

COMO A MÍDIA FLUI

Uma voice note, do WhatsApp à resposta

📱 Evolution API → webhook
PTT chega como OGG/Opus + mediaKey; n8n puxa base64 (ou referência S3/MinIO — melhor p/ retenção LGPD).

🗣 Groq Whisper large-v3-turbo → \$0.04/h
Aceita OGG/Opus DIRETO (zero ffmpeg). Transcript vira dado auditável no audit chain.

🛡 PII scrub (app/services/pii.py)
3 camadas antes de qualquer LLM: CPF/RG/protocolo mascarados. Provider nunca vê dado bruto.

🧠 Gemini 3.6 Flash via LiteLLM
Transcript + contexto + tools (agenda, protocolo, emolumento) → resposta em PT-BR a 275 t/s.

💬 Resposta (texto ou áudio TTS pt)
Mandou áudio, recebe áudio: Gemini TTS nativo \$0.03/min. HITL: protocolo sempre nasce DRAFT.

PLANO DE AÇÃO

Setup em 3 passos (~\$16-35/mês)

1

Cérebro: Gemini API key no AI Studio (paid)

~\$15

Billing on → `gemini-3.6-flash` no LiteLLM como default do bot. Nunca free tier (treina com dados). Escalonamento p/ 3.1 Pro nos casos complexos.

2

Ouvidos: Groq Whisper + olhos nativos

~\$1

Voice notes → `groq-whisper-large-v3-turbo` (OGG direto, transcript auditável). Fotos/PDFs → visão nativa do próprio Gemini (sem custo extra de provider).

3

Opcional: MiniMax Plus \$20 (flat backup + voz)

+\$20

TTS PT com 73 vozes dentro da quota + fallback flat p/ texto quando convier. Com ele: ~\$35/mês total — ainda dentro dos \$40.

FAQ

❓ Por que não o MiniMax Plus \$20 que venceu na v1?

A v1 olhava **coding agent**; esta olha **chatbot de atendimento**. Pro bot, o MiniMax tem 2 gaps fatais: **não existe áudio-input** na plataforma (WhatsApp = voice note) e o τ³-Banking é **13%** (perde o fio em fluxo multi-turn com tools). Ele continua ótimo como flat backup + TTS — só não como o cérebro.

❓ E o risco de alucinação com taxas e prazos?

Arquitetura que já existe no projeto resolve: **LLMs só vêm de tools** (emolumento.py, DB, audit) — o LLM só redige, e protocolo nasce DRAFT (HITL). Como cinto extra, evitamos os que inventam quando não sabem: GPT-5.6 Sol (10) e DeepSeek V4 (4-6) ficam fora de document Q&A; MiniMax (84) e Claude (74) são os mais honestos.

❓ Gemini free tier não daria de graça?

Tecnicamente sim, LGPD-mente **não**: no free tier o conteúdo **treina modelos Google** e passa por revisão humana. No paid tier, não treina e há DPA. Como o scrub de PII roda antes, o risco residual é baixo — mas a regra do projeto é zero treino. Paid é obrigatório.

❓ E se o volume explodir (20k+ conversas/mês)?

Gemini 3.6 Flash escala linear (~\$44 em 20k) — aí entra routing no LiteLLM: triagem/FAQ → **3.5 Flash-Lite** (\$0.25/\$1.50, ~60% do tráfego), casos reais → 3.6 Flash. Total volta p/ ~\$25-30. O budget \$40 aguenta ~4x o volume atual.

Resumo: Gemini 3.6 Flash PAYG (~\$15) + Groq Whisper (~\$1) = **~\$16/mês** — PT-BR #1, multimodal nativo completo, o mais rápido, tool-use ok, LGPD limpo. Com MiniMax Plus como flat backup + TTS: **~\$35/mês**. Melhor entrega possível dentro de US\$20-40.

Fontes primárias: seus dados Artificial Analysis v4.1 (Intelligence/Coding/Agentic Index, Multilingual PT, τ³-Banking, Omniscience — jul/2026). Validação e gaps por 8 research agents em 22/jul/2026: ai.google.dev, docs.x.ai, platform.minimax.io, DashScope/Model Studio, platform.openai.com, docs.anthropic.com, api-docs.deepseek.com, docs.z.ai, Evolution API + n8n docs. Custos estimados p/ 5k conversas/mês, 30% c/ mídia.

2º Serviço Notarial de Uberlândia · Cartório Bot · Uso interno · v2 chatbot