

O melhor plano de **US\$20-40** pro chatbot do **Cartório**

Foco: **atendimento WhatsApp** com voz, foto, PDF e vídeo — flows agênticos, melhor PT-BR, menor custo. A v3 funde a v1 (coding) + v2 (chatbot) e **corrige uma errata**: o MiniMax **tem visão e vídeo nativos** sim — o único gap real dele é áudio-IN, que se resolve com \$0.40/mês.

11 provedores

áudio · foto · PDF · vídeo

PT-BR · barato · agêntico · honesto

VEREDITO EM 10 SEGUNDOS

MiniMax Plus + Groq Whisper

~\$21/mês

MiniMax Token Plan Plus (\$20 flat) como cérebro: M3 vê fotos e vídeos nativamente, fala PT com 73 vozes TTS na quota, é o #1 em seguir script (IFBench 83%) e o #2 em não alucinar (84) — os dois números que mais importam num bot jurídico com HITL. O gap de áudio-IN se resolve com **Groq Whisper a \$0.04/h** (aceita o OGG/Opus do WhatsApp direto). Custo previsível, OAuth nativo OpenClaw+Hermes, e **já é o stack que roda hoje**.

+ Gemini 3.6 Flash PAYG

escalonamento premium multimodal (PT-BR 94, 275 t/s)

+\$5-10

ERRATA DA V2 · TRANSPARÊNCIA

O que a v2 errou sobre o MiniMax

→ "Multimodal-55%" → **errado**. O M3 aceita **imagem e vídeo nativos** (image_url / video_url , OpenAI-compat) + API-vlm dedicada (~\$0.0035/chamada). Visão: **sim, e você já usa**. Multimodal real: **~80%**.

→ "t3-43% desqualifica" → **ponderação errada**. t3-Banking mede fluxo aberto multi-turn. O bot do Cartório é **fluxo scripted + HITL** (n8n orquestra, LLM redige, protocolo nasce DRAFT). Nesse cenário, mandam **IFBench (#1, 83%) e anti-alucinação (#2, 84)** — ambos do MiniMax.

→ **O gap que sobra é real e barato**: MiniMax não tem STT. Groq Whisper turbo resolve a \$0.04/h aceitando OGG/Opus **direto** — \$0.40/mês em 5k voice notes.

O NÚMERO QUE DESTRAVA A DECISÃO

Mídia custa ~\$1/mês. O cérebro é o custo.

Em 5.000 conversas/mês com 30% de média: STT Groq (10h) = **\$0.40**, 450 fotos de RG/CPF = **\$0.45**, PDFs = **\$0.15**. Escolha o provider pelo **cérebro** (PT-BR + disciplina de script + não inventar fato) e plugue a mídia mais barata. E um cérebro **flat de \$20** não tem surpresa na fatura.

RANKING · PERFIL DE CHATBOT JURÍDICO SCRIPTED

Os 5 finalistas

1

MiniMax Plus + Groq STT

M3 · flat \$20 · OAuth nativo

~\$21/mês total

Português ~87%

Multimodal 80%

Segue script 83 #1

Anti-alucinação 84 #2

visão + vídeo nativos

TTS PT 73 vozes na quota

OAuth OpenClaw+Hermes

áudio-IN via Groq \$0.04/h

Por que voltou ao topo: o bot do Cartório é scripted + HITL — e nesse jogo o M3 é imbatível: obedece o fluxo (IFBench #1), não inventa taxa nem prazo (Omniscience 84, #2), vê a foto do RG e o vídeo do cliente nativamente, responde em áudio PT com voz própria, custa **flat \$20** sem surpresa e já está plugado no OpenClaw/Hermes/LiteLLM. Zero refactor.

2

Gemini 3.6 Flash

Google · PAYG AI Studio

~\$15/mês real

Português 94 #1

Multimodal 100%

Velocidade 275 t/s

Custo ~\$15

áudio+foto+PDF 1000p+vídeo nativo

PT-BR #1

Opus (codec WhatsApp) fora da lista oficial — testar/convert

O melhor indiscutível: PT-BR 94, o mais rápido do índice, multimodal mais completo. Entra como **escalonamento** no LiteLLM (casos complexos, PDFs gigantes, segunda opinião) por +\$5-10/mês — e como plano de contingência se um dia sair do MiniMax. Asterisco real: voice note é OGG/Opus, que não consta na lista oficial de formatos — na prática o STT Groq já resolve antes.

3

xAI API · grok-4.3

pay-as-you-go · ZDR

~\$27/mês real

Português 93

Multimodal 70%

Tool-use (t3) 33% #1

Velocidade 69 t/s

#1 em fluxo aberto c/ tools

ZDR self-serve

STT \$0.10/h

PDF fraco sob ZDR

Se um dia o bot virar fluxo aberto: t3-Banking 33% (#1), PT-BR 93, STT próprio barato e Zero Data Retention verificável por header (ouro p/ auditoria LGPD). Hoje, mais caro que o setup MiniMax sem ganho no cenário scripted.

4

Qwen · DashScope stack

qwen3.7-plus + ASR + VL

~\$20/mês real

Português ~85?

Multimodal 85%

Tool-use (t3) 31%

Custo mídia \$3.75

ASR PT oficial \$0.126/h

VL-Flash \$0.05/1M

PT-BR texto não benchmarkado

latência Singapura

O "mais completo barato": texto + ASR PT + OCR + omni numa só API (~\$20/mês tudo). Mas PT-BR do texto sem benchmark e DC em Singapura (+200ms). Vale piloto grátis (1M tokens/90 dias) como **terceiro rail**.

5

Claude Haiku 4.5

Anthropic · PAYG + cache

~\$31/mês real

Português 92

Multimodal 60%

Documentos PDF 600 pág

Anti-alucinação 74

PDF 600 páginas inline — o melhor p/ escrituras

retenção zero default

sem áudio: precisa STT externo

Especialista, não generalista: PT-BR premium (92-94 na família), PDF nativo de 600 páginas e privacidade default impecável. Papel: **escalonamento de documentos longos** (escrituras, processos) — não a voz principal do bot.

DEEP DIVE · O VENCEDOR

MiniMax Token Plan Plus — \$20 flat

RECOMENDADO

MiniMax-M3

1M CONTEXTO (512K GARANT.)

83% / 84

IFBENCH #1 · ANTI-ALUCINA #2

2 endpoints

/V1 OPENAI + /ANTHROPIC

OAuth nativo

OPENCLAW + HERMES

Foto de RG/CPF/comprovante

visão nativa no M3 (image_url) ou API-vlm

na quota ✓

Vídeo do cliente

M3 aceita video_url nativamente

na quota ✓

TTS PT — 73 vozes

speech~2.8 turbo/hd; responde áudio p/ quem mandou áudio

na quota ✓

Voice note IN (único gap)

Groq whisper-large-v3-turbo — OGG/Opus direto

\$0.04/h

PDF escaneado

página → imagem → visão M3; texto → extração local grátis

~\$0

✓ Disciplina de script: IFBench #1 (83%) — menus, LGPD rights e HITL seguidos à risca, turno após turno.

✓ Não inventa fato: Omniscience 84 (#2) — essencial p/ taxas, prazos e documentos. GPT-5.6 Sol (10) e DeepSeek (4-6) ficam de fora por isso.

✓ Flat = previsível: texto + visão + vídeo + TTS na mesma quota; overflow cai p/ Credits pré-pagos (~\$1/1.000) sem derrubar o bot.

✓ Pico de throttle: 04:00-06:30 BRT (madrugada) — impacto quase zero num bot BR.

✓ Plug-and-play: OAuth minimax-portal (OpenClaw) + minimax-oauth (Hermes); LiteLLM nativo. Já roda hoje — zero refactor.

✓ LGPD ✓: PII scrubbed em 3 camadas antes (app/services/pii.py) — provider só recebe texto mascarado; transcript Groq vira dado auditável no audit chain.

COMPARATIVO DIRETO

PROVIDER	\$/MÊS	PT-BR	VISÃO/VÍDEO	ÁUDIO IN	SCRIPT
MiniMax + Groq	~\$21	~87	nativo	Groq	83 #1
Gemini 3.6 Flash	~\$15	94	nativo	Opus ⚠	médio
xAI grok-4.3	~\$27	93	visão	\$0.10/h	médio
Qwen stack	~\$20	~85?	nativo	\$0.126/h	médio
Claude Haiku 4.5	~\$31	92	visão	não tem	médio
OpenAI 5.4-nano+STT	~\$21	91	nativo	\$0.003/min	médio
DeepSeek V4-Flash	~\$7	90	texto-only	não tem	médio

"Script" = IFBench (seguir instrução/fluxo). "Alucina" = AA-Omniscience (maior = melhor). Num bot de cartório, fatos (taxas/prazos) vêm SEMPRE de tools/DB — o LLM só redige; mesmo assim, os que inventam (GPT 10, DeepSeek 4-6) ficam fora de document Q&A. Custo: 5k conversas/mês, 30% c/ mídia.

COMO A MÍDIA FLUI

Uma voice note, do WhatsApp à resposta

📱

Evolution API → webhook

PTT chega como OGG/Opus + mediaKey; n8n puxa base64 (ou referência S3/MinIO — melhor p/ retenção LGPD).

🗂️

Groq Whisper large-v3-turbo → \$0.04/h

Aceita OGG/Opus DIRETO (zero ffmpeg). Transcript vira dado auditável no audit chain.

🛡️

PII scrub (app/services/pii.py)

3 camadas antes de qualquer LLM: CPF/RG/protocolo mascarados. Provider nunca vê dado bruto.

🧠

MiniMax M3 via LiteLLM/OpenClaw

Transcript + foto/vídeo (nativo) + tools (agenda, protocolo, emolumento) → resposta seguindo o script à risca.

💬

Resposta (texto ou áudio TTS PT)

Mandou áudio, recebe áudio: TTS MiniMax na quota. Caso complexo → escala p/ Gemini 3.6 Flash. HITL: protocolo sempre DRAFT.

PLANO DE AÇÃO

Setup em 3 passos (~\$21-31/mês)

1

Cérebro: MiniMax Token Plan Plus — \$20

\$20

OAuth no OpenClaw (minimax-portal) e Hermes (minimax-oauth). Default: MiniMax-M3 . Ativar Credits pré-pagos (~\$5) p/ overflow de janela.

2

Ouvidos: Groq Whisper — ~\$1

~\$1

Voice notes → whisper-large-v3-turbo (OGG direto, transcript auditável). Fotos/vídeos → visão nativa do M3 (na quota, \$0 extra).

3

Opcional: Gemini 3.6 Flash — +\$5-10

+\$5-10

Escalonamento no LiteLLM p/ casos complexos, PDFs gigantes e segunda opinião (PT-BR 94). Total com opcional: ~\$26-31/mês — folgado nos \$40.

FAQ

? Por que o MiniMax voltou ao topo depois da v2?

Porque a v2 errou duas vezes: (1) disse que ele era fraco em multimodal — **ele vê imagem e vídeo nativamente**, só não tem STT (resolvido com \$0.40/mês de Groq); (2) pesou o t3-Banking (fluxo aberto) mais que o IFBench (seguir script) — mas o bot do Cartório **é scripted + HITL**, e aí o M3 é #1 em obediência e #2 em não alucinar. O resto (flat \$20, OAuth nativo, já rodando) é bônus.

? E o PT-BR do Gemini (94) não ganha do MiniMax (~87)?

Ganha — por isso o Gemini é o escalonamento oficial. Mas na prática o M3 (~87-88, família M2 benchmarkada) atende bem o registro de atendimento, e a diferença não compensa perder: custo flat, TTS PT na quota, OAuth nativo e **zero refactor** do stack atual. PT-BR 94 fica a \$5-10 de distância, ligável por intent no LiteLLM.

? E o risco de alucinação com taxas e prazos?

Dupla proteção: arquitetura (fatos **só via tools** — emolumento.py , DB, audit; LLM só redige; protocolo nasce DRAFT) + modelo honesto (MiniMax 84, #2 em não-alucinação). Os que inventam quando não sabem (GPT-5.6 Sol 10, DeepSeek 4-6) ficam fora de document Q&A.

? E se o volume explodir (20k+ conversas/mês)?

O Plus tem janelas 5h/semanal — o overflow cai automático nos Credits (pré-pagos, ~\$1/1.000). Se virar rotina, migra o cérebro p/ **PAYG do próprio M3** (\$0.30/\$1.20 por 1M ≈ \$15-25 em 20k) sem trocar provider nem código. Budget \$40 aguenta ~4x o volume atual.

Resumo: MiniMax Plus \$20 (cérebro flat: texto + visão + vídeo + TTS PT) + Groq Whisper ~\$1 (áudio-IN) = **~\$21/mês**. Escalonamento Gemini 3.6 Flash: **~\$26-31/mês** total. Melhor entrega em US\$20-40: script seguido à risca, não inventa fato, vê foto/vídeo, fala PT, OAuth nativo — e já roda hoje.

Fontes: Artificial Analysis v4.1 (Intelligence/Coding/Agentic Index, Multilingual PT, t3-Banking, IFBench, Omniscience → jul/2026) + 16 research-agent runs (22/jul/2026): ai.google.dev, platform.minimax.io, docs.x.ai, DashScope, platform.openai.com, docs.anthropic.com, api-docs.deepseek.com, docs.z.ai, Evolution API + n8n docs + validação de uso real (visão/vídeo MiniMax em produção). v3 corrige a errata de multimodal da v2.