

O melhor plano de US\$20–40 pro Agent do Cartório

Rodamos **8 agents de pesquisa** — um por provedor — cruzando 184 modelos do Artificial Analysis (Intelligence v4.1, Coding & Agentic Index) com preço real, auth (API key / OAuth) e compatibilidade nativa com **OpenClaw + Hermes**.

11 provedores

9 planos analisados

Foco: barato · rápido · agêntico · PT-BR

VEREDITO EM 10 SEGUNDOS

MiniMax Token Plan Plus

\$20/mês

Único plano da faixa com **OAuth nativo nos DOIS gateways** (OpenClaw `minimax-portal` + Hermes `minimax-oauth`), endpoint OpenAI e Anthropic-compatible, modelo **MiniMax-M3** (1M de contexto) e ToS que permite uso em agentes oficialmente. É o que já roda no stack do Cartório — migração zero.

+ DeepSeek V4 PAYG

fallback barato no LiteLLM (cache hit ~grátis)

≈ \$30/mês

ANTES DE ASSINAR QUALQUER COISA

- ⚠ **Assinatura de chat ≠ backend de bot**
- ✗ **ChatGPT Plus (\$20)** — OAuth só p/ Codex local; ToS proíbe alimentar serviço de terceiros. Sem API inclusa.
- ✗ **Claude Pro (\$20)** — OAuth de assinatura em gateway viola ToS (enforcement em 2026). Fable 5 nem incluído mais.
- ✗ **SuperGrok (\$30)** — billing separado da API xAI. Zero créditos de API.
- ✗ **Google AI Pro (\$20)** — não libera Gemini API; OAuth consumer instável p/ produção.

RANKING CUSTO-BENEFÍCIO

Os 5 finalistas

1

MiniMax Plus
MiniMax-M3 · 1M ctx

\$20
flat/mês

Agentic Index

35

Intelligence

44

Velocidade

99
t/s

Custo/tarefa

\$0.12

OAuth nativo OpenClaw+Hermes

/v1 + /anthropic

ToS ✓ p/ agentes

Por que venceu: melhor equilíbrio agentic × preço × plug-and-play. M3 bate 83.5 no BrowseComp (> Opus 4.7), \$0.30/\$1.20 por 1M no PAYG, e o plano flat vira teto de custo. Já é o provider atual — zero refactor.

2

DeepSeek V4 PAYG
V4-Flash / V4-Pro

~\$10
uso típico

Agentic Index

32–36

Intelligence

40–44

Português

90

Custo/tarefa

\$0.02

O mais barato, disparado

cache hit ~grátis

sem restrição de uso

Papel no stack: \$0.14/\$0.28 por 1M (Flash), endpoint OpenAI e Anthropic, zero restrição de caso de uso. Ideal como fallback no LiteLLM e p/ tarefas baratas em volume. PT-BR 90 — o melhor entre os baratos.

3

GLM Coding Plan Lite
GLM-5.2 · Z.AI

\$18
flat/mês

Agentic Index

43

Intelligence

51

Velocidade

182
t/s

Custo/tarefa

\$0.47

ToS cita OpenClaw oficialmente

só p/ coding tools

Melhor score por dólar em inteligência (51) e agentic (43) — mas o ToS restringe a ferramentas de coding. Uso: **dev agents do time** (não o bot de atendimento).

4

Kimi Allegretto
Kimi K3 · 1M ctx · Moonshot

\$39
flat/mês

Agentic Index

50

Intelligence

57

Velocidade

34
t/s

Custo/tarefa

\$0.95

#1 contexto longo (AA-LCR 75%)

PT-BR não confirmado

Upgrade premium: K3 é #3 geral em inteligência e #1 em long-context/briefcase — perfeito p/ ler processos e escrituras longas. Mas é lento (34 t/s), caro por tarefa, PT-BR não benchmarkado e ToS p/ dev tools. Alternativa se o M3 não der conta.

5

xAI API · grok-4.3
pay-as-you-go

~\$19
uso típico

Agentic Index

46

Intelligence

54

Português

93

Velocidade

69
t/s

ZDR (Zero Data Retention)

PT-BR 93 (Grok 4)

SuperGrok \$30 não dá API

Wild card LGPD: único com Zero Data Retention self-serve e PT-BR 93. \$1.25/\$2.50 por 1M. Ótimo 3º provider no LiteLLM p/ intents sensíveis. A assinatura SuperGrok, porém, não inclui API — ignore ela.

DEEP DIVE · O VENCEDOR

MiniMax Token Plan Plus — \$20/mês

RECOMENDADO

MiniMax-M3
MODELO INCLUÍDO

1M tokens
CONTEXTO (512K GARANT.)

2 endpoints
/v1 OPENAI +
/ANTHROPIC

OAuth + key
NOS 2 GATEWAYS

✓ **OpenClaw:** OAuth nativo `minimax-portal` (global + CN) — pluga sem API key.

✓ **Hermes:** OAuth PKCE nativo `minimax-oauth` — único provedor da faixa com OAuth nos dois.

✓ **Claude Code / OpenCode:** `ANTHROPIC_BASE_URL=https://api.minimax.io/anthropic` + Subscription Key. OpenCode tem M3 built-in.

✓ **LiteLLM (stack atual):** provider nativo — só apontar a Subscription Key.

✓ **Overflow:** estourou a janela 5h/semanal, cai automático p/ Credits pré-pagos (não derruba o bot).

✓ **Benchmarks M3:** SWE-Bench Pro 59% · Terminal-Bench 66% · BrowseComp 83.5 · MCP Atlas 74.2.

✓ **LGPD:** PII scrubbed em 3 camadas antes (`app/services/pii.py`) — inalterado, provider só recebe texto mascarado.

COMPARATIVO DIRETO

PLANO	\$/MÊS	AGENTIC	INTEL	PT-BR	OAUTH OC/H
MiniMax Plus	\$20	35	44	~87	sim/sim
DeepSeek V4	~\$10	32–36	40–44	90	key/key
GLM Lite	\$18	43	51	~86	key/key
Kimi Allegretto	\$39	50	57	?	sim/sim
xAI grok-4.3	~\$19	46*	54*	93	key/key
Gemini 3.6 Flash	~\$8	39	50	94	key/key
ChatGPT Plus	\$20	—	51	91	ToS ✗
Claude Pro	\$20	—	53	92–94	ToS ✗
SuperGrok	\$30	—	30	93	sem API

*Grok 4.5 (API ~\$35/mês). PT-BR: Artificial Analysis Multilingual Index. "~" = estimativa por família de modelo. Uso típico: ~5k conversas/mês, ~2k tok in / 500 out por conversa.

PLANO DE AÇÃO

Setup em 3 passos (~\$30/mês)

1

Assinar MiniMax Token Plan Plus — \$20

Conectar via OAuth no OpenClaw (`minimax-portal`) e Hermes (`minimax-oauth`). Modelo default do bot: `MiniMax-M3` . Ativar Credits pré-pagos p/ overflow automático.

2

DeepSeek V4 como fallback — ~\$10

API key em `api.deepseek.com` no LiteLLM com `fallbacks` + router por intent: triagem/FAQ → V4-Flash (cache hit ~grátis), agêntico → M3.

3

Opcional p/ dev: GLM Coding Lite — \$18

P/ os coding agents do time (ToS OK, cita OpenClaw). Não usar no bot de atendimento. Total com opcional: ~\$48/mês.

FAQ

+ Por que não ChatGPT Plus ou Claude Pro, se têm os maiores scores?

+ E se o MiniMax M3 não aguentar um caso complexo?

+ LGPD muda em algo?

Resumo: MiniMax Plus \$20 (bot + agents) + DeepSeek PAYG ~\$10 (fallback) = **~\$30/mês**. Melhor custo-benefício real da faixa US\$20–40: barato, rápido (99 t/s), agêntico (35), PT-BR ok, OAuth nativo OpenClaw + Hermes e ToS limpo.

Fontes: Artificial Analysis Intelligence Index v4.1 / Coding Index / Agentic Index / Multilingual PT (jul 2026) · docs oficiais: `minimax.io`, `deepseek.com`, `z.ai`, `kimicom.ai`, `x.ai`, `openai.com`, `anthropic.com`, `ai.google.dev`, `docs.openclaw.ai`, Hermes docs — coletados por 8 research agents em 22/jul/2026. Scores de planos consumer (Plus/Pro/SuperGrok) referem-se ao modelo, não ao plano.

2º Serviço Notarial de Uberlândia · Cartório Bot · Uso interno